

Plan your trip with

Comment construire un pipeline ETL pour recommander automatiquement les meilleures destinations de vacances en France ?

70 %

des utilisateurs
Kayak

souhaitent plus d'informations sur leur destination avant de réserver.

Kayak n'a pas encore d'outil de recommandation basé sur des données réelles.

Python

Selenium

OpenWeatherMap API

Pandas

S3 / MinIO

PostgreSQL


Aïcha FATELLAH

Formation Fullstack Data Engineering | 2026

02 Architecture du pipeline ETL & Données collectées

Projet Kayak - Pipeline ETL complet

Collecte des données



Données collectées

35 villes géocodées (Nominatim)

105 hôtels scrapés (Selenium)

6 CSV générés dont 4 sur S3 (MinIO)

2 tables SQL cities + hotels (PostgreSQL)

35L × 13C dataset final enrichi

Résultats - Visualisations interactives Plotly

35

villes
géocodées

105

hôtels
scrapés

4

CSV uploadés
sur S3 (MinIO)


2

tables SQL
sur PostgreSQL

Top 5 Destinations

Meilleur compromis météo / hôtels

Top 20 Hôtels

Les mieux notés sur Booking.com

Data Lake : S3 / MinIO

CSV

villes_coords.csv

35 villes + GPS · local uniquement

CSV

villes_meteo_coords.csv

Météo 5j · 3 Ko

CSV

hotels_booking_35_villes.csv

Données brutes · local uniquement

CSV

hotels_cleaned_full.csv

105 hôtels nettoyés · 52 Ko

CSV

villes_scores_aggregated.csv

Scores agrégés · 1 Ko

CSV

kayak_final_enriched_data.csv

Dataset final · 3 Ko

Data Warehouse : PostgreSQL

TABLE cities

```
city_id · city · lat/lon · temp · rain ·  
travel_score
```

TABLE hotels

```
city_id (FK) · hotel_name · rating · url · lat/lon
```

Formule du travel_score

40% temp · 40% note · 20% faible
pluie

Température (40 %) : critère météo principal

Note hôtelière (40 %) : qualité des hébergements

Faible pluie (20 %) : critères normalisés 0-1 puis pondérés

05 Points techniques, Limites & Conclusion

Ce que ce projet démontre

- Collecte multi-sources : API REST + Scraping Selenium
- Pipeline ETL structuré avec scoring métier Pandas
- Conformité RGPD : aucune donnée personnelle · clés protégées (.env)
- Résilience : checkpoint CSV après chaque ville
- Architecture Data Lake / Data Warehouse séparée (MinIO · PostgreSQL)

Limites identifiées

- Booking bloque à 3 hôtels/ville → rotation proxies
- Descriptions hôtels à N/A → WebDriverWait
- Pondération fixe 40/40/20 → curseur utilisateur

35

villes
géocodées

105

hôtels
scrapés

4

CSV sur
S3 / MinIO

2

tables SQL
sur PostgreSQL

Perspectives

- Automatisation via AWS Lambda + EventBridge
- Enrichir le score avec l'API SNCF (prix trains)
- Intégrer le volume de pluie cumulé au score
- Exposer le pipeline via une API REST FastAPI