

Plan your trip with

Comment construire un pipeline ETL pour recommander automatiquement les meilleures destinations de vacances en France ?

70 %

des utilisateurs
Kayak

souhaitent plus d'informations sur leur destination avant de réserver.

Kayak n'a pas encore d'outil de recommandation basé sur des données réelles.

Python

Selenium

OpenWeatherMap API

Pandas

AWS S3

AWS RDS


Aïcha FATHELLAH

Formation Fullstack Data Engineering | 2026

02 Architecture du pipeline ETL & Données collectées

Projet Kayak - Pipeline ETL complet

Collecte des données



Données collectées

35 villes géocodées (Nominatim)

104 hôtels scrapés (Selenium)

6 CSV générés dont 4 sur AWS S3

2 tables SQL cities + hotels (RDS)

35L × 13C dataset final enrichi

Résultats - Visualisations interactives Plotly

35

villes
géocodées

104

hôtels
scrapés

4

CSV uploadés
sur AWS S3

2

tables SQL
sur AWS RDS


Top 5 Destinations

Meilleur compromis météo / hôtels



Top 20 Hôtels

Les mieux notés sur Booking.com



AWS S3 : Data Lake

CSV

villes_coords.csv

35 villes + GPS · local uniquement

CSV

villes_meteo_coords.csv

Météo 7j · 3 Ko

CSV

hotels_booking_35_villes.csv

Données brutes · local uniquement

CSV

hotels_cleaned_full.csv

104 hôtels nettoyés · 52 Ko

CSV

villes_scores_aggregated.csv

Scores agrégés · 1 Ko

CSV

kayak_final_enriched_data.csv

Dataset final · 3 Ko

AWS RDS : Data Warehouse

TABLE cities

```
city_id · city · lat/lon · temp · rain ·  
travel_score
```

TABLE hotels

```
city_id (FK) · hotel_name · rating · url · lat/lon
```

Formule du travel_score

40% temp · 40% note · 20% faible
pluie

Température (40 %) : critère météo principal

Note hôtelière (40 %) : qualité des hébergements

Faible pluie (20 %) : critères normalisés 0-1 puis pondérés

05 Points techniques, Limites & Conclusion

Ce que ce projet démontre

- Collecte multi-sources : API REST + Scraping Selenium
- Pipeline ETL structuré avec scoring métier Pandas
- Conformité RGPD : aucune donnée personnelle · clés protégées (.env)
- Résilience : checkpoint CSV après chaque ville
- Architecture Data Lake S3 / Data Warehouse RDS séparée

35

villes
géocodées

104

hôtels
scrapés

4

CSV sur
AWS S3

2

tables SQL
sur RDS

Limites identifiées

- Booking bloque à 3 hôtels/ville → rotation proxies
- Descriptions hôtels à N/A → WebDriverWait
- Pondération fixe 40/40/20 → curseur utilisateur

Perspectives

- Automatisation via AWS Lambda + EventBridge
- Enrichir le score avec l'API SNCF (prix trains)
- Intégrer le volume de pluie cumulé au score
- Exposer le pipeline via une API REST FastAPI