

Plan your trip with

Comment construire un pipeline ETL pour recommander automatiquement les meilleures destinations de vacances en France ?

70 %

des utilisateurs
Kayak

souhaitent plus d'informations sur leur destination avant de réserver.

Kayak n'a pas encore d'outil de recommandation basé sur des données réelles.

Python

Selenium

OpenWeatherMap API

Pandas

AWS S3


AWS RDS

Aïcha FATHELLAH

Formation Fullstack Data Engineering — Jedha | CSDS Bloc 1 | 2026

02 Architecture du pipeline ETL & Données collectées

Projet Kayak — Pipeline ETL complet



Données collectées

35 villes géocodées (Nominatim)

105 hôtels scrapés (Selenium)

6 fichiers CSV générés par le pipeline

2 tables SQL cities + hotels (RDS)

35L × 9C dataset final enrichi

Résultats — Visualisations interactives Plotly

35

villes
géocodées

105

hôtels
scrapés

6

fichiers CSV
sur AWS S3


2

tables SQL
sur AWS RDS

Top 5 Destinations

Meilleur compromis météo / hôtels


Top 5 Destinations — Meilleur compromis Météo / Hôtels



Top 20 Hôtels

Les mieux notés sur Booking.com

Top 20 Hôtels les mieux notés en France



AWS S3 : Data Lake

CSV

villes_coords.csv

35 villes + GPS · 2 Ko

CSV

villes_meteo_coords.csv

Météo 7j · 3 Ko

CSV

hotels_booking_35_villes.csv

Données brutes · 51 Ko

CSV

hotels_cleaned_full.csv

105 hôtels nettoyés · 51 Ko

CSV

villes_scores_aggregated.csv

Scores agrégés · 1 Ko

CSV

kayak_final_enriched_data.csv

Dataset final · 3 Ko

AWS RDS : Data Warehouse

TABLE cities

```
city_id · city · lat/lon · temp · rain ·  
travel_score
```

TABLE hotels

```
hotel_id · city_id (FK) · hotel_name · rating · url
```

Formule du travel_score

$$(\text{temp} \times 0.5) + (\text{note} \times 2 \times 0.5)$$

Température (50 %) : indicateur météo principal

Note hôtelière (50 %) : $\times 2$ pour ramener sur même échelle

Pondération ajustable selon les préférences utilisateur

05 Points techniques, Limites & Conclusion

Ce que ce projet démontre

- Collecte multi-sources : API REST + Scraping Selenium
- Pipeline ETL structuré avec scoring métier Pandas
- Sécurité : clés API protégées via python-dotenv (.env)
- Résilience : checkpoint CSV après chaque ville
- Architecture Data Lake S3 / Data Warehouse RDS séparée

Limites identifiées

- Booking bloque à 3 hôtels/ville → rotation proxies
- Descriptions hôtels à N/A → WebDriverWait
- Pondération fixe 50/50 → curseur utilisateur

35

villes
géocodées

105

hôtels
scrapés

6

CSV sur
AWS S3

2

tables SQL
sur RDS

Perspectives

- Automatisation via AWS Lambda + EventBridge
- Enrichir le score avec l'API SNCF (prix trains)
- Intégrer la probabilité de pluie dans le scoring
- Exposer le pipeline via une API REST FastAPI