

Projet : La plateforme de jeux vidéo de Steam 🐙

Steam, la plateforme de jeux vidéo 🐙 960 min



Description de l'entreprise 📄

Steam est une plateforme de distribution numérique de jeux vidéo appartenant à Valve . Lancée en septembre 2003 en tant que client logiciel pour la mise à jour automatique des jeux Valve, elle s'est étendue à la distribution de titres tiers fin 2005. Steam propose diverses fonctionnalités, telles que la gestion des droits numériques (DRM), le matchmaking sur serveurs de jeu avec le système anti-triche de Valve , les réseaux sociaux et le streaming de jeux . Le client Steam offre notamment la mise à jour automatique des jeux, le stockage cloud de la progression et des fonctionnalités communautaires comme la messagerie instantanée, des interfaces superposées et une boutique virtuelle d' objets à collectionner .

Projet 🚧

Vous travaillez pour Ubisoft , un éditeur français de jeux vidéo. Ils souhaitent sortir un nouveau jeu vidéo révolutionnaire ! Ils vous ont demandé de réaliser une analyse globale des jeux disponibles sur la plateforme Steam afin de mieux comprendre l'écosystème du jeu vidéo et les tendances actuelles.

Objectifs 🎯

L'objectif principal de ce projet est de comprendre les facteurs qui influencent la popularité ou les ventes d'un jeu vidéo. Cependant, votre supérieur vous a demandé de profiter de cette occasion pour analyser le marché mondial du jeu vidéo.

Pour mener à bien ce projet, vous devrez adopter différents niveaux d'analyse. Votre responsable vous a fourni une liste d'exemples de questions qui pourraient s'avérer intéressantes :

Analyse au niveau « macro »

- Quel éditeur a sorti le plus de jeux sur Steam ?
- Quels sont les jeux les mieux notés ?
- Y a-t-il eu des années avec plus de sorties de jeux ? Y a-t-il eu plus ou moins de sorties de jeux pendant la pandémie de Covid, par exemple ?
- Comment les prix sont-ils distribués ? Y a-t-il beaucoup de jeux avec une réduction ?
- Quelles sont les langues les plus représentées ?
- Existe-t-il beaucoup de jeux interdits aux enfants de moins de 16/18 ans ?

Analyse des genres

- Quels sont les genres les plus représentés ?
- Existe-t-il des genres qui présentent un meilleur ratio avis positifs/avis négatifs ?
- Certains éditeurs ont-ils des genres de prédilection ?
- Quels sont les genres les plus lucratifs ?

Analyse de la plateforme

- La plupart des jeux sont-ils disponibles sur Windows/Mac/Linux ?
- Certains genres sont-ils généralement disponibles de préférence sur certaines plateformes ?

Vous êtes libre de suivre ces directives ou de choisir un angle d'analyse différent, pourvu que votre analyse révèle des informations pertinentes et utiles. 🤖

Portée de ce projet

Vous devrez utiliser **Databricks** et **PySpark** pour réaliser cette analyse exploratoire des données (EDA). Plus précisément, vous devrez utiliser **l'outil de visualisation de Databricks** pour créer les visualisations.

L'ensemble de données est disponible dans notre compartiment S3 à l'URL suivante : `s3://full-stack-bigdata-datasets/Big_Data/Project_Steam/steam_game_output.json` .

Aides 🦊

Pour vous aider à mener à bien ce projet, voici quelques conseils qui devraient vous être utiles :

- Pour adopter différents niveaux d'analyse, il peut être utile de créer différents dataframes.
- Étant donné que l'ensemble de données est semi-structuré avec un **schéma imbriqué** , les méthodes de Pyspark telles que `getField()` et `explode()` peuvent vous aider.
- Ce jeu de données contient des champs de texte et de date : PySpark propose des fonctions utilitaires pour manipuler efficacement ces types de données 💡
- Vous pouvez utiliser des fonctions d'agrégation `groupBy` pour effectuer une analyse segmentée.

Livrable 📁

Pour mener à bien ce projet, vous devez livrer :

- Un ou plusieurs notebooks incluant la manipulation de données avec PySpark et la visualisation de données avec l'outil de tableau de bord de Databrick.
- Pour que le jury puisse consulter toutes les visualisations, veuillez utiliser le bouton « publier » des notebooks Databricks afin de créer une URL publique où une copie de votre notebook sera disponible.
- Lorsque vous utilisez le bouton « Publier », Databricks peut vous indiquer que la taille de votre notebook dépasse la limite autorisée. Dans ce cas, il vous suffit de le diviser en plusieurs notebooks.
- Veuillez copier-coller le(s) lien(s) vers vos carnets publiés dans votre dépôt Github afin que le jury puisse y accéder facilement. 😊



Project_Steam_part1

Python ▾

File Edit View Run Help [Last edit was 3 days ago](#) [Provide feedback](#)

▶ Run all

■ Terminated ▾

Publish

Cmd 1

```
1 from pyspark.sql import functions as F
```

Command took 0.06 seconds -- by aurelie@jedha.co at 23/06/2023 18:14:59 on My Cluster

Cmd 2

