

360 min

soldes Walmart



Description de l'entreprise

Walmart Inc. est une multinationale américaine de la grande distribution qui exploite une chaîne d'hypermarchés, de grands magasins à prix réduits et de supermarchés aux États-Unis. Son siège social se trouve à Bentonville, dans l'Arkansas. L'entreprise a été fondée par Sam Walton en 1962.

Projet

Le service marketing de Walmart vous a demandé de concevoir un modèle d'apprentissage automatique capable d'estimer les ventes hebdomadaires de leurs magasins avec la meilleure précision possible. Ce modèle leur permettrait de mieux comprendre l'influence des indicateurs économiques sur les ventes et pourrait servir à la planification de futures campagnes marketing.

Objectifs

Le projet peut être divisé en trois étapes :

- Partie 1 : effectuer une analyse exploratoire des données (EDA) et tous les prétraitements nécessaires pour préparer les données à l'apprentissage automatique.
- Partie 2 : entraîner un **modèle de régression linéaire** (ligne de base)
- Partie 3 : éviter le surapprentissage en entraînant un **modèle de régression régularisé**

Portée de ce projet

Pour ce projet, vous travaillerez avec un jeu de données contenant des informations sur les ventes hebdomadaires réalisées par différents magasins Walmart, ainsi que d'autres variables telles que le taux de chômage ou le prix du carburant, qui pourraient s'avérer utiles pour prédire le volume des ventes.

Ce jeu de données provient d'une compétition Kaggle, mais nous y avons apporté quelques modifications. Veuillez vous assurer d'utiliser **notre** jeu de données personnalisé (disponible sur JULIE).



Livrable

Pour mener à bien ce projet, votre équipe doit :

- Créez des visualisations
- Entraînez au moins un **modèle de régression linéaire** sur l'ensemble de données, qui prédit le montant des ventes hebdomadaires en fonction des autres variables.
- Évaluer les performances du modèle en utilisant une métrique pertinente pour les problèmes de régression
- Interprétez les coefficients du modèle pour identifier les caractéristiques importantes pour la prédiction.
- Entraînez au moins un modèle avec **régularisation (Lasso ou Ridge)** pour réduire le surapprentissage.

Aides

Pour vous aider à mener à bien ce projet, voici quelques conseils qui devraient vous être utiles :

Partie 1 : EDA et prétraitement des données

Commencez votre projet en explorant votre ensemble de données : créez des figures, calculez des statistiques, etc.

Ensuite, vous devrez effectuer un prétraitement des données. Vous pouvez suivre les instructions du *modèle de prétraitement* . Des transformations spécifiques devront également être planifiées, par exemple sur la colonne *Date* qui ne peut pas être incluse telle quelle dans le modèle. Voici quelques pistes qui pourraient vous être utiles 

Prétraitement à planifier avec pandas

Supprimez les lignes où les valeurs cibles sont manquantes :

- Ici, la variable cible (Y) correspond à la colonne *Ventes_hebdomadaires* . On peut constater ci-dessus que certaines valeurs sont manquantes dans cette colonne.

- Nous n'utilisons jamais de techniques d'imputation sur la cible : cela pourrait créer un biais dans les prédictions !
- Ensuite, nous supprimerons simplement les lignes de l'ensemble de données pour lesquelles la valeur de *Weekly_Sales* est manquante.

Création de caractéristiques exploitables à partir de la colonne *Date* : La colonne *Date* ne peut pas être incluse telle quelle dans le modèle. Vous pouvez soit la supprimer, soit créer de nouvelles colonnes contenant les caractéristiques numériques suivantes :

- *année*
- *mois*
- *jour*
- *jour de la semaine*

Supprimer les lignes contenant des valeurs invalides ou aberrantes : Dans ce projet, seront considérées comme aberrantes toutes les valeurs numériques qui ne se situent pas dans la plage définie. $[\bar{X} - 3\sigma, \bar{X} + 3\sigma]$ Cela concerne les colonnes : *Température* , *Prix du carburant* , *IPC* et *Chômage*.

Variable cible (Y) que nous allons tenter de prédire afin de la distinguer des autres : *Ventes_hebdomadaires*

Prétraitements à planifier avec scikit-learn

Variables explicatives (X) Nous devons identifier quelles colonnes contiennent des variables catégorielles et quelles colonnes contiennent des variables numériques, car elles seront traitées différemment.

- Variables catégorielles : *Magasin*, *Indicateur_Vacances*
- Variables numériques : *Température*, *Prix du carburant*, *IPC*, *Chômage*, *Année*, *Mois*, *Jour*, *Jour de la semaine*

Partie 2 : Modèle de base (régression linéaire)

Une fois votre premier modèle entraîné, n'oubliez pas d'évaluer ses performances sur les ensembles d'entraînement et de test. Êtes-vous satisfait des résultats ? Par ailleurs, il serait intéressant d'analyser les valeurs des coefficients du modèle afin d'identifier les caractéristiques importantes pour la prédiction. Pour ce faire, l'attribut `.coef_` de la classe `LinearRegression` de scikit-

learn pourrait s'avérer utile. Consultez le lien suivant pour plus d'informations 😊 https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LinearRegression.html

Partie 3 : Lutter contre le surentraînement

Dans cette dernière partie, vous devrez entraîner un **modèle de régression linéaire régularisée**. Vous trouverez ci-dessous quelques classes utiles dans la documentation de scikit-learn :

- https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Ridge.html#sklearn.linear_model.Ridge
- https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.Lasso.html#sklearn.linear_model.Lasso

Question bonus

Dans les modèles de régression régularisée, un hyperparamètre appelé *force de régularisation* peut être ajusté avec précision afin d'obtenir les meilleures prédictions généralisées sur un jeu de données donné. Cet ajustement est possible grâce à la classe GridSearchCV de scikit-learn : https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html

Vous trouverez également ici quelques exemples d'utilisation de GridSearchCV avec les modèles Ridge ou Lasso : <https://alfurka.github.io/2018-11-18-grid-search/>