

W A L M A R T

Prédiction des ventes hebdomadaires

Projet Machine Learning supervisé - Régression linéaire et régularisée

Stack technique : Python | pandas | scikit-learn | matplotlib

Sommaire

01 Contexte et objectifs du projet

02 Description du jeu de données

03 Analyse exploratoire - EDA

04 Prétraitement des données

05 Modélisation - Régression linéaire (baseline)

06 Régularisation - Ridge et Lasso

07 Résultats et comparaison des modèles

08 Conclusions et recommandations

01 - Contexte et objectifs

Contexte

Walmart Inc. est le premier distributeur mondial, fondé en 1962 par Sam Walton.

Le service marketing souhaite un modèle capable d'estimer les ventes hebdomadaires de ses magasins.

Un tel modèle permettrait de mieux comprendre l'influence des indicateurs économiques et d'optimiser les campagnes marketing.

Objectifs du projet

Partie 1

EDA et prétraitement des données

Partie 2

Modèle de régression linéaire (baseline)

Partie 3

Régularisation Ridge et Lasso pour réduire l'overfitting

Bonus

Optimisation de l'hyperparamètre alpha via GridSearchCV

02 - Description du jeu de données

150

observations initiales

8

variables d'origine

71

observations après nettoyage

26

features après preprocessing

Variables du dataset

Variable	Type	Description	Rôle
Weekly_Sales	Numérique	Ventes hebdomadaires (\$)	Target (y)
Store	Catégorielle	Identifiant du magasin (19 magasins)	Feature X
Holiday_Flag	Catégorielle	Présence d'un jour férié (0 ou 1)	Feature X
Temperature	Numérique	Température régionale (degrés F)	Feature X
Fuel_Price	Numérique	Prix du carburant (\$)	Feature X
CPI	Numérique	Indice des prix à la consommation	Feature X
Unemployment	Numérique	Taux de chômage régional (%)	Feature X
Date	Date	Semaine - décomposée en Year/Month/Day (DayOfWeek écartée - variance nulle)	Feature X (transformée)

03 - Analyse exploratoire (EDA)

Graphique 1 - Distribution des ventes

Distribution bimodale (270k\$ à 2,8M\$), médiane ~1,2M\$.
Deux groupes de magasins aux profils très distincts. Moustache droite allongée : hétérogénéité inter-magasins réelle.

Graphique 2 - Evolution temporelle

Tendance haussière et saisonnalité régulière, justifiant l'extraction de features Year, Month, Day.

Graphique 3 - Hétérogénéité inter-magasins

Certains magasins génèrent 3x plus de ventes.
Store est la variable la plus déterminante du modèle.

Graphique 4 - Indicateurs économiques

Fêtes : +7,5% de ventes. IPC (CPI) : $r = -0,29$ - hausse = perte de pouvoir d'achat = baisse des ventes. Chômage élevé : tendance négative marquée sur les ventes.

Graphique 5 - Matrice de corrélation

Aucune variable isolée n'est fortement corrélée à la cible ($\max |r| = 0.29$).
Combinaison nécessaire.

Graphique 6 - Corrélation Features vs Target

CPI ($|r|=0.287$) et Température ($|r|=0.166$) sont les plus corrélées.
Tous les $|r|$ restent sous 0.30.

04 - Prétraitement des données

Prétraitement avec pandas

Étape 1

Suppression des 14 lignes où Weekly_Sales est manquant
(aucune imputation sur la variable cible)

Étape 2

Décomposition de Date en 3 features : Year, Month, Day (DayOfWeek écartée - variance nulle)

Étape 3

Retrait des outliers hors $[X - 3\sigma, X + 3\sigma]$ sur Temperature, Fuel_Price, CPI, Unemployment

Prétraitement avec scikit-learn

OneHotEncoder

Store (19 magasins - 1 = 18 cols)
Holiday_Flag (2 valeurs - 1 = 1 col)
drop='first' pour éviter la multi colinéarité

StandardScaler

Temperature, Fuel_Price, CPI, Unemployment
Year, Month, Day
Centre (mean=0) et réduit (std=1)

Résultat final

X_train : (56, 26) | X_test : (15, 26)
26 colonnes = 18 + 1 + 7 (cohérent)

05 - Modélisation - Régression linéaire (baseline)

0.9865

R² Train

0.9313

R² Test

127 770 \$

MAE Test

149 685 \$

RMSE Test

Écart Train-Test : $0.9865 - 0.9313 = 0.0552$ - Surapprentissage (overfitting) détecté - nécessaire de régulariser

Top variables - impact sur Weekly_Sales

 + Store (identité magasin)	Dominant
 + Year	Elevé
 - Unemployment	Modéré
 + Month	Modéré
 + Holiday_Flag	Faible
 - CPI, Temperature	Faible

Diagnostic du modèle

Predicted vs Actual :

Les prédictions se regroupent autour de la droite parfaite ($y=x$), confirmant la performance globale du modèle.

Analyse des résidus :

Les résidus sont distribués autour de 0 sans structure particulière. Les hypothèses du modèle linéaire sont respectées.

06 - Régularisation - Ridge et Lasso

La régularisation pénalise les grands coefficients pour réduire l'overfitting.

L'hyperparamètre alpha contrôle la force de la pénalité : plus alpha est grand, plus les coefficients sont contraints.

Ridge (L2) - Meilleur alpha = 0.1

Principe :

Pénalise la somme des carrés des coefficients (L2). Réduit tous les coefficients sans les annuler.

GridSearchCV (cv=5) :

Meilleur alpha = 0.1. Le R^2 chute rapidement au-delà : une régularisation trop forte conduit au sous-apprentissage.

Résultats :

R^2 Train : 0.9821 | R^2 Test : 0.9365

MAE : 117 536 \$ | RMSE : 143 863 \$

Ecart Train-Test : 0.0456 (réduit vs Baseline)

Lasso (L1) - Meilleur alpha = 1000

Principe :

Pénalise la somme des valeurs absolues (L1). Peut annuler certains coefficients : sélection automatique de variables.

GridSearchCV (cv=5) :

Meilleur alpha = 1000. Le R^2 augmente jusqu'au bord de la grille : élargir la recherche (5 000, 10 000) pour confirmer l'optimum global.

Résultats :

R^2 Train : 0.9844 | R^2 Test : 0.9438

MAE : 114 353 \$ | RMSE : 135 369 \$


Ecart Train-Test : 0.0406 (meilleur des 3)

07 - Résultats et comparaison des modèles


Tableau de performance comparatif

Modèle	R ² Train	R ² Test	MAE Test	RMSE Test	Ecart Train-Test
Régression Linéaire	0.9865	0.9313	127 770 \$	149 685 \$	0.0552
Ridge (alpha = 0.1)	0.9821	0.9365	117 536 \$	143 863 \$	0.0456
Lasso (alpha = 1000)	0.9844	0.9438	114 353 \$	135 369 \$	0.0406

R² Test par modèle



MAE Test par modèle (\$)



08 - Conclusions et recommandations

Modèle recommandé : Lasso (alpha = 1000) - Meilleur R^2 Test (0.9438), MAE et RMSE les plus faibles, overfitting le plus réduit, sélection automatique de variables.

Variables les plus importantes

1 Store

Facteur dominant - hétérogénéité forte entre magasins

2 Year

Tendance haussière des ventes dans le temps

3 Unemployment

Corrélation négative - chômage élevé = ventes faibles

4 Month

Saisonnalité mensuelle des ventes

5 Holiday_Flag

Semaines de fêtes : +7.5% de ventes en moyenne

Limites et perspectives

Limites :

- Dataset réduit (71 obs. après nettoyage) - résultats à confirmer sur plus de données
- La grille alpha Lasso (max 1000) pourrait être élargie pour confirmer l'optimum
- La régression linéaire suppose une relation linéaire entre X et y

Perspectives :

- Tester des modèles non linéaires : Random Forest, XGBoost
- Enrichir le dataset avec des données externes (météo, événements)
- Mettre en production via une API pour prédiction en temps réel

09 - Implications pour le service marketing

Le modèle Lasso quantifie l'influence des indicateurs économiques - leviers actionables pour planifier les campagnes

Jours fériés (Holiday_Flag)

+7,5%

Concentrer les budgets promotionnels sur les semaines de fêtes. Planifier les campagnes en avance.

IPC - Indice des Prix à la Consommation

$r = -0,29$

Renforcer les offres prix lors des phases d'inflation. Adapter le positionnement sur les produits essentiels.

Chômage (Unemployment)

Négatif

Intensifier les promotions dans les bassins d'emploi fragilisés. Adapter la stratégie par zone géographique.

Clé de lecture - combinaison des signaux

Aucun indicateur n'agit seul. Fêtes + chômage élevé + inflation = stratégie promotionnelle spécifique, différente d'une zone à fort emploi.

Merci pour votre attention

Questions ?

Projet Machine Learning supervisé - Walmart Weekly Sales Prédiction

0.9438

R² Test Lasso

114 353 \$

MAE Test

135 369 \$

RMSE Test

Lasso (a=1000)

Modèle retenu