

Défi du Taux de Conversion

Prédiction des abonnements à la newsletter
Data Science Weekly

Métrique : Score F1 | Gradient Boosting : F1 = 0,7569

Plan de la présentation

01

Contexte & Données

Description du projet, jeu de données, variables

02

Analyse Exploratoire (EDA)

Distribution, corrélations, anomalies, visualisations

03

Modélisation

3 modèles comparés : Régression Logistique, Random Forest, Gradient Boosting

04

Résultats & Prédictions

Scores F1, ROC-AUC, prédictions sur le jeu de test

05

Recommandations

Leviers d'action pour améliorer le taux de conversion

01 Contexte & Données

Contexte du projet

www.datascienceweekly.org

Newsletter hebdomadaire sur la data science rédigée par des experts indépendants.

Objectif : Prédire si un visiteur va s'abonner à partir de son comportement de navigation.

Compétition de type Kaggle

Métrique imposée : Score F1

Variables du jeu de données

country

Catégorielle

Pays (China, Germany, UK, US)

age

Numérique

Âge du visiteur

new_user

Binaire

1=nouveau, 0=existant

source

Catégorielle

Ads / Seo / Direct

total_pages_visited

Numérique

Pages vues en session


converted ★

CIBLE

1=abonné, 0=non abonné

02 Analyse Exploratoire — Déséquilibre & Anomalie

Distribution variable cible



■ Non converti (96,8%) ■ Converti (3,2%)

284 580

Visiteurs (train)

3,2 %

Taux de conversion

31 620

Visiteurs (test)

Anomalie détectée : âge = 123 ans

2 lignes avec un âge aberrant (111 et 123 ans) — clairement une erreur de saisie (< 0,001% des données). Ces lignes ont été supprimées pour ne pas biaiser le modèle.

Le fort déséquilibre des classes (3,2% de positifs) impose l'utilisation du paramètre `class_weight='balanced'` pour la régression logistique et le Random Forest.

02 Analyse Exploratoire — Corrélations & Pages visitées

Corrélation avec converted

total_pages_visited **+0,53**


country (enc.) **+0,08**

age **-0,09**

new_user **-0,15**


source (enc.) **-0,00**

Taux de conversion par segment de pages (%)




02 Analyse Exploratoire — Variables catégorielles


Taux de conversion par pays (%)



Taux de conversion par source (%)



Taux de conversion new_user (%)



Chine : 0,1%

Accès Internet restreint — probablement un problème de collecte.

Utilisateurs existants 5x plus

new_user=0 → 7,2% vs new_user=1 → 1,4% : ils connaissent déjà le site.

03 Modélisation — 3 modèles comparés

Régression Logistique

BASELINE

- max_iter=1000
- class_weight='balanced'
- Normalisation : StandardScaler

F1

0,512

ROC-AUC

0,986

Modèle de référence simple et interprétable.

Random Forest

AMÉLIORÉ

- n_estimators=200
- max_depth=10
- min_samples_leaf=10
- class_weight='balanced'

F1

0,555

ROC-AUC

0,984

Gestion native des non-linéarités, robuste au bruit.

Gradient Boosting

MEILLEUR

- n_estimators=200
- learning_rate=0,05
- max_depth=4
- subsample=0,8

F1

0,757


ROC-AUC

0,986

Construction séquentielle, corrige les erreurs itérativement.

04 Résultats — Comparaison des performances

Score F1 par modèle



Gradient Boosting : +25 pts de F1 vs baseline. ROC-AUC > 0,98 pour les 3 modèles.

0,757

Meilleur F1

Gradient Boosting

0,986

ROC-AUC max

Tous les modèles

31 620


Prédictions test

dont 837 convertis prédicts (2,65%)

Validation et robustesse

- ✓ Validation croisée à 5 plis : Gradient Boosting confirmé meilleur modèle (F1 moyen 0,764)
- ✓ Stabilité élevée : écart-type des scores de seulement 0,006 sur les 5 plis
- ✓ Aucun surapprentissage : écarts entraînement / validation très faibles (0,0004 à 0,015)
- ✓ Encodage one-hot des variables catégorielles : aucun ordre artificiel introduit

04 Résultats — Importance des variables (Gradient Boosting)



Interprétation

87,5 % **total_pages_visited**

Prédicteur quasi unique. Le comportement de navigation prime sur tout le reste.

5,7 % **new_user**

Utilisateurs existants convertissent 5x plus que les nouveaux.

4,1 % **country**

La Chine tire le score vers le bas (0,1% de conversion).

2,5 % **age**

Les 18-25 ans convertissent légèrement plus.

0,1 % **source**

La source du trafic a un impact négligeable.

05 Recommandations — Leviers d'action

1

PRIORITÉ HAUTE

Augmenter le nombre de pages visitées

C'est le levier n°1 (87,5% de l'importance). Mettre en place des liens recommandés, une sidebar d'articles récents et des aperçus de numéros précédents pour inciter les visiteurs à explorer davantage de contenu.

Impact potentiel : très élevé

2

PRIORITÉ HAUTE

Cibler les utilisateurs existants

Les visiteurs déjà connus convertissent 5x plus (7,2% vs 1,4%). Mettre en place du retargeting pour inciter les visiteurs à revenir sur le site. Un visiteur qui revient est un futur abonné.

Impact potentiel : élevé

3

PRIORITÉ MOYENNE

Cibler la tranche 18-25 ans

Les jeunes professionnels (étudiants, bootcamps data) représentent le segment qui convertit le mieux par tranche d'âge (5,1%). Orienter les campagnes vers LinkedIn et les formations data.

Impact potentiel : modéré

4

PRIORITÉ BASSE

Investiguer le cas Chine

Le taux de 0,1% en Chine semble lié à des contraintes techniques ou réglementaires (accès internet). Ce n'est probablement pas un problème de contenu mais d'accessibilité du site.

À investiguer

Conclusion

- ✓ Gradient Boosting retenu : $F1 = 0,757$ — meilleur score parmi les 3 modèles testés
- ✓ `total_pages_visited` : prédicteur dominant à 87,5% d'importance
- ✓ 837 prédictions de conversion générées sur le jeu de test (31 620 visiteurs)
- ✓ Levier prioritaire : augmenter l'engagement sur le site pour faire passer les visiteurs au-delà de 15 pages vues