

défi du taux de conversion 360 min



Dans ce projet, vous participerez à une compétition d'apprentissage automatique comme celles organisées par **Kaggle** (<https://www.kaggle.com/>). Vous pourrez utiliser les notebooks Jupyter comme d'habitude, mais vous devrez soumettre les prédictions de votre modèle à votre enseignant/assistant d'enseignement afin que ses performances soient évaluées de manière indépendante. Les scores obtenus par les différentes équipes seront affichés dans un classement.

Description d'un défi d'apprentissage automatique 🚴 🚴

- Dans les défis d'apprentissage automatique, l'ensemble de données est toujours divisé en deux fichiers :
 - Le fichier *data_train.csv* contient **des données étiquetées**, c'est-à-dire des variables explicatives (X) et la variable cible à prédire (Y). Vous utiliserez ce fichier pour entraîner votre modèle comme d'habitude : division des données en ensembles d'entraînement et de test, prétraitement, évaluation des performances, essais de différents modèles, optimisation des hyperparamètres, etc.
 - Le fichier *data_test.csv* contient de nouveaux exemples qui n'ont pas servi à l'entraînement du modèle. Il est au même format que *data_train.csv*, mais **sans étiquette** : la variable cible Y a été supprimée. Une fois votre modèle entraîné, vous utiliserez *data_test.csv* pour effectuer des prédictions que vous enverrez à l'équipe organisatrice. Celle-ci pourra ainsi évaluer les performances de votre modèle de manière indépendante, en évitant toute tricherie.

- Les prédictions de votre modèle seront comparées aux valeurs réelles et un classement sera établi, où seront stockés les scores de toutes les équipes du monde.
- Tous les participants sont informés de la métrique qui sera utilisée pour évaluer les scores. Vous devez vous assurer d'utiliser la même métrique pour évaluer vos performances d'entraînement et de test !

Description de l'entreprise

www.datascienceweekly.org est une newsletter réputée, rédigée par des data scientists indépendants. Toute personne peut s'inscrire sur ce site web en y indiquant son adresse e-mail afin de recevoir chaque semaine des actualités sur la science des données et ses applications !

Projet

Les data scientists à l'origine de la newsletter souhaitent mieux comprendre le comportement des utilisateurs visitant leur site web. Ils aimeraient savoir s'il est possible de construire un modèle prédictif de l'abonnement à la newsletter, à partir de quelques informations seulement. Ils envisagent ensuite d'analyser les paramètres de ce modèle afin de mettre en évidence les caractéristiques pertinentes pour expliquer ce comportement et, éventuellement, identifier un nouveau levier d'action pour améliorer le taux de conversion de la newsletter.

Ils ont conçu un concours visant à élaborer un modèle permettant de prédire les *conversions* (c'est-à-dire la date à laquelle un utilisateur s'abonnera à la newsletter). Pour ce faire, ils ont mis à disposition en open source un jeu de données contenant des informations sur le trafic de leur site web. Afin d'évaluer les performances des différentes équipes participantes, ils ont opté pour le **score F1** .

Objectifs

Le projet peut être divisé en quatre étapes :

- Partie 1 : Effectuer une analyse exploratoire des données (EDA) et les prétraitements, puis entraîner un modèle de base avec le fichier *data_train.csv*.
- Partie 2 : Améliorez le score F1 de votre modèle sur votre ensemble de test (vous pouvez essayer l'ingénierie des caractéristiques, la sélection de caractéristiques, la régularisation, les

modèles non linéaires, l'optimisation des hyperparamètres par recherche sur grille, etc.)

- Partie 3 : Une fois satisfait(e) du score de votre modèle, vous pouvez l'utiliser pour effectuer des prédictions avec le fichier *data_test.csv* . Vous devrez exporter les prédictions dans un fichier .csv qui sera envoyé à Kaggle (en réalité, à votre enseignant(e) ou assistant(e) 🤖). Vous pouvez soumettre autant de résultats que vous le souhaitez et n'hésitez pas à tester différents modèles !
- Partie 4 : Prenez le temps d'analyser les paramètres de votre meilleur modèle. Existe-t-il des leviers d'action permettant d'améliorer le taux de conversion de la newsletter ? Quelles recommandations feriez-vous à l'équipe ?

Livrable 📁

Pour mener à bien ce projet, votre équipe doit :

- Créez des figures pertinentes pour l'EDA.
- Entraînez au moins un modèle qui prédit les conversions et évaluez ses performances (f1, matrices de confusion).
- Soumettez au moins une contribution au classement
- Analysez les paramètres de votre meilleur modèle et formulez des recommandations pour améliorer le taux de conversion à l'avenir.

Aides 🦊

Pour vous aider avec la méthodologie, nous avons créé un modèle (**02-Conversion_rate_challenge_template.ipynb**) dans lequel toutes les étapes d'entraînement et de prédiction sont implémentées pour un modèle très simple (régression logistique à une seule variable). Veuillez utiliser ce modèle et n'hésitez pas à modifier les étapes d'analyse exploratoire des données, de prétraitement et d'entraînement ! Que la force soit avec vous ! 🧪🧪