



Le commerce électronique de The North Face : booster les ventes en ligne !

Description de l'entreprise 📄

The North Face est une entreprise américaine spécialisée dans les articles de loisirs de plein air, fondée en 1968 pour équiper les grimpeurs. Elle produit des vêtements, des chaussures et du matériel de plein air. À la fin des années 1990, sa clientèle s'est élargie au-delà des seuls amateurs de plein air et, dans les années 2000, la marque est devenue une icône de la mode.

Projet 🚧

Le service marketing souhaite exploiter les solutions d'apprentissage automatique pour dynamiser les ventes en ligne sur le site web : <https://www.thenorthface.fr/>

Ils ont identifié deux solutions majeures susceptibles d'avoir un impact considérable sur les taux de conversion :

- Déploiement d'un **système de recommandation** permettant de suggérer aux utilisateurs des produits complémentaires similaires à ceux qui les intéressent déjà. Ces recommandations pourraient se concrétiser par une section « Ces produits pourraient également vous intéresser... » apparaissant sur chaque page produit du site web.
- Amélioration de la structure du catalogue produits grâce à **l'extraction de thématiques** . L'idée est d'utiliser des méthodes non supervisées pour remettre en question les catégories existantes : est-il possible de trouver de nouvelles catégories de produits plus adaptées à la navigation sur le site web ?

Objectifs 🎯

Le projet peut être divisé en trois étapes :

1. Identifier les groupes de produits ayant des descriptions similaires.
2. Utilisez les groupes de produits similaires pour construire un algorithme de système de recommandation simple.
3. Utilisez des algorithmes de modélisation thématique pour évaluer automatiquement les thèmes latents présents dans les descriptions des articles.

Portée de ce projet 🖼️

Dans le cadre de ce projet, vous travaillerez avec un corpus de descriptions d'articles issues du catalogue de produits The North Face. Les données sont disponibles ici :

👉👉 [Catalogue de produits The North Face](#) 👉👉

Aides 🦊

Pour vous aider à mener à bien ce projet, voici quelques conseils qui devraient vous être utiles :

Prétraitement des données textuelles

- Tout d'abord, vous devrez effectuer quelques prétraitements pour nettoyer le corpus (en particulier, n'oubliez pas de supprimer les mots vides et de lemmatiser les documents). Pour cette étape, vous aurez besoin de `pandas` et `spacy` .
- Ensuite, vous pouvez encoder les textes avec **la transformation TF-IDF** (cela peut être fait avec `scikit-learn` `TFIDFVectorizer`).

Partie 1 : Groupes de produits aux descriptions similaires

Pour cette partie, vous devrez entraîner un **modèle de clustering** qui créera des groupes de produits dont les descriptions sont « proches » les unes des autres.

- Vous pouvez utiliser cette méthode `DBSCAN` pour effectuer un clustering sur la matrice TF-IDF. Pour les textes, la distance à utiliser est la distance cosinus plutôt que la distance euclidienne. Il vous faut trouver des valeurs pour `eps` les paramètres `min_samples` permettant d'obtenir 10 à 20 clusters avec peu de valeurs aberrantes.
- Vous pouvez afficher un graphique `wordcloud` pour chaque groupe afin d'analyser les résultats et de voir si les groupes contiennent des mots différents.

Partie 2 - Système de recommandation

Vous pouvez ensuite utiliser les identifiants de cluster de la partie 1 pour créer un **système de recommandation**. L'objectif est de pouvoir suggérer à un utilisateur des produits similaires à ceux qui l'intéressent. Pour ce faire, nous considérerons que les produits appartenant au même cluster sont similaires.

- Créez une fonction `find_similar_items` qui prend en argument `item_id` l'identifiant d'un produit et qui renvoie une liste de 5 identifiants d'articles appartenant au même cluster que le produit passé en argument.
- Utilisez une fonction Python `input()` pour permettre à l'utilisateur de choisir un produit et lui suggérer des articles similaires.

Partie 3 : Modélisation thématique

Cette partie est indépendante des deux autres.

L'objectif est d'utiliser un modèle LSA pour extraire automatiquement les thèmes latents dans les descriptions des produits.

- Utilisez `TruncatedSVD` pour extraire des thèmes de la matrice TF-IDF. Vous pouvez essayer des valeurs `n_components` permettant d'obtenir 10 à 20 thèmes. Enregistrez la matrice encodée dans une variable nommée `topic_encoded_df`.
- Contrairement au clustering, l'analyse sémantique latente (LSA) permet d'associer chaque document à un ensemble de thèmes. De ce fait, il est plus complexe d'interpréter ces thèmes comme des catégories : un document peut en effet être lié à plusieurs thèmes simultanément. Pour simplifier l'analyse, il est conseillé d'extraire le thème principal de chaque document.
- Comme dans la partie 1, vous pouvez afficher `wordclouds` les résultats pour les analyser.

Livrable

Pour mener à bien ce projet, votre équipe doit :

- Entraînez au moins un **modèle de clustering** sur le corpus et affichez des nuages de mots décrivant les clusters.
- Développez un programme Python simple qui permet à un utilisateur de saisir l'identifiant d'un produit qui l'intéresse, puis d'obtenir une liste d'articles similaires.
- Entraînez au moins un **modèle TruncatedSVD** sur le corpus et affichez des nuages de mots décrivant les thèmes latents.