

THE NORTH FACE

Commerce électronique : dynamiser les ventes en ligne

Apprentissage automatique appliqué au catalogue produits

01

Clustering DBSCAN

Regrouper les produits
par descriptions similaires

02

Recommandation

Suggérer des produits
complémentaires

03

Modélisation LSA

Extraire les thèmes
latents du catalogue

CONTEXTE ET PROJET

L'ENTREPRISE

The North Face

Fondée en 1968 pour équiper les grimpeurs, The North Face produit des vêtements, chaussures et équipements de plein air.

D'abord spécialisée outdoor, la marque est devenue une icône de la mode dans les années 2000.

OBJECTIF MARKETING

Booster les ventes sur thenorthface.fr grâce au machine learning.

1

Système de recommandation
"Vous aimerez aussi..." sur chaque page produit

2

Extraction de thèmes
Réévaluer et restructurer les catégories du catalogue

PIPELINE TECHNIQUE



Toutes les étapes sont implémentées en Python dans le notebook Jupyter fourni.

PARTIE 1 - CLUSTERING DBSCAN

PRINCIPE

Algorithme basé sur la densité : détecte automatiquement le nombre de clusters

Distance cosinus adaptée aux données textuelles TF-IDF

Identifie les outliers (label = -1) sans les forcer dans un cluster

Paramètres calibrés

$eps = 0.72$ | $min_samples = 3$ | $metric = 'cosine'$ | $algorithm = 'brute'$

14

clusters formés

4.4%

taux d'outliers

242


max produits / cluster

3

min produits / cluster

Les wordclouds (page suivante) confirment la cohérence sémantique de chaque cluster : sous-vêtements, vestes, pantalons, chaussures, sacs, laine mérinos, etc.

Wordclouds par cluster DBSCAN - The North Face



PARTIE 2 - SYSTÈME DE RECOMMANDATION

1

Identifier le cluster

On récupère le cluster DBSCAN du produit consulté par l'utilisateur.

2

Calculer la similarité

On calcule la similarité cosinus entre ce produit et tous ses voisins du même cluster via la matrice TF-IDF.

3

Retourner les 5 plus proches

On retourne les 5 produits par ordre décroissant de similarité cosinus (fonction `find_similar_items`).

Avantage clé : tri par similarité cosinus décroissante — les recommandations sont les plus pertinentes du cluster, pas tirées au hasard.

PARTIE 3 - MODÉLISATION THÉMATIQUE LSA

Analyse Sémantique Latente (LSA) avec TruncatedSVD

Contrairement au clustering, la LSA projette chaque produit dans un espace multi-thèmes : un même produit peut être associé à plusieurs thèmes simultanément. Le thème principal est extrait via la composante de valeur absolue maximale.

15

thèmes latents
extraits

26%



variance expliquée
par 15 composantes

500










produits
recodés

`topic_encoded_df`

matrice
document × thèmes



Wordclouds par theme LSA (TruncatedSVD) - The North Face



SYNTHÈSE ET CONCLUSIONS

01

Clustering DBSCAN

- 14 clusters sémantiques identifiés
- Seulement 4.4% d'outliers
- Distance cosinus + TF-IDF + spaCy
- Wordclouds : cohérence validée

02

Recommandation

- Fonction find_similar_items
- Tri par similarité cosinus décroissante
- 5 produits les plus pertinents
- Interface utilisateur via input()

03

Modélisation LSA

- 15 thèmes latents extraits
- Matrice topic_encoded_df
- Représentation multi-thèmes
- Complémentaire au clustering

Ces trois composantes forment ensemble un système complet de valorisation du catalogue e-commerce The North Face.