



Détecteur de Spam

AT&T

Classification de SMS par apprentissage profond

Deep Learning | NLP | Transfert d'apprentissage

Contexte et problématique

AT&T Inc.

1re entreprise mondiale de télécommunications
en chiffre d'affaires

168,8 Mds \$

de revenus en 2022

13ème au Fortune 500
en 2022

3ème opérateur mobile
aux États-Unis

Le problème

Exposition massive
aux messages indésirables (spam)

Détection manuelle
devenue insuffisante et non scalable

Objectif :
*construire un détecteur automatique capable de
classer chaque SMS dès sa réception, basé uniquement
sur son contenu.*

Exploration des données — spam.csv

5 572

messages bruts


403

doublons supprimés

5 169

après nettoyage

Répartition Ham / Spam



Statistiques de longueur (caractères)

Classe	Moyenne	Médiane	Max
Ham	70,5	52	910
Spam	137,9	149	224

Split stratifié 80 / 20

Entraînement : 4 135 exemples (spam : 12,62 %)

Test : 1 034 exemples (spam : 12,67 %)

Stratification garantissant l'équilibre des classes dans les deux sous-ensembles.

Prétraitement et Modèle 1 - Embedding + BiLSTM



Prétraitement

Nettoyage textuel : Minuscules, suppression des caractères spéciaux, normalisation des espaces. Chiffres conservés.

Tokenisation Keras : Vocabulaire 10 000 mots · padding post · max 100 tokens · token <OOV> pour les mots inconnus.

Tokenisation DistilBERT : WordPiece · max 128 tokens · tokens [CLS] et [SEP] automatiques.



Modèle 1 - Embedding + BiLSTM

Embedding
10k · dim 64

BiLSTM
64 units

Dense 32
ReLU

Sigmoid
P(spam)

Optimiseur : Adam · Binary Crossentropy

Callbacks : EarlyStopping (patience=3) + ReduceLROnPlateau

Arrêt à l'époque 2 · meilleurs poids restaurés

Résultats sur le jeu de test (1 034 messages)

98,36 %

Accuracy

93,33 %

F1-Score

98,40 %

AUC-ROC

Classe	Précis.	Rappel	F1	N
Ham	0,99	0,99	0,99	903
Spam	0,96	0,91	0,93	131

Modèle 2 - Transfert d'apprentissage avec DistilBERT



Poids pré-entraînés sur des milliards de phrases en anglais — gelés. Seule la tête de classification est entraînée.

class_weight='balanced' : poids spam $\approx 3,96\times$ | poids ham $\approx 0,57\times$ - compense le déséquilibre 87/13

Adam ($\text{lr} = 2\text{e-}5$) | 5 époques | EarlyStopping (patience=2) | **Seuil optimal : 0,60** (maximisation du F1-Score)

Résultats - Modèle 2 sur le jeu de test (1 034 messages, seuil = 0,60)

98,26 %

Accuracy

92,91 %

F1-Score (spam)

99,37 %

AUC-ROC

Classe	Précision	Rappel	F1-Score	Support
Ham	0,99	0,99	0,99	903
Spam	0,96	0,90	0,93	131
Accuracy			0,98	1 034

Comparaison des performances et recommandation

Métriques sur le jeu de test (1 034 messages)




Tableau comparatif		
Métrique	Mod. 1	Mod. 2
Accuracy	98,36 %	98,26 %
F1-Score	93,33 %	92,91 %
AUC-ROC	98,40 %	99,37 %
Seuil décision	0,50	0,60



Modèle 1 - Infrastructure légère - F1 légèrement supérieur · inférence sans GPU · déploiement immédiat sur les serveurs SMS d'AT&T.



Modèle 2 - Précision maximale - AUC-ROC 99,37 % · meilleure discrimination · recommandé si AT&T dispose d'une infrastructure GPU.

Annexe - Rapport de classification détaillé

(Slide de réserve - à présenter sur demande du jury)

Modèle 1 - Embedding + BiLSTM

Classe	Précision	Rappel	F1-Score	Support
Ham	0,99	0,99	0,99	903
Spam	0,96	0,91	0,93	131
Accuracy			0,98	1 034

Matrice de confusion (Modèle 1)

VN (ham→ham) : **893**

FP (ham→spam) : **10**

FN (spam→ham) : **7** VP (spam→spam) : **124**

Modèle 2 - DistilBERT (seuil = 0,60)

Classe	Précision	Rappel	F1-Score	Support
Ham	0,99	0,99	0,99	903
Spam	0,96	0,90	0,93	131
Accuracy			0,98	1 034

Matrice de confusion (Modèle 2)

VN (ham→ham) : **891**

FP (ham→spam) : **12**

FN (spam→ham) : **13** VP (spam→spam) : **118**