

Projet Getaround



Analyse des retards et optimisation du prix de location

Pipeline de Machine Learning - de l'analyse exploratoire au déploiement en production

Mai 2026

Contexte et problématique

Getaround, plateforme de location de véhicules entre particuliers, fait face à un double enjeu produit.



Enjeu 1 - Friction client

Les retours en retard entre deux locations consécutives génèrent des frictions pour le conducteur suivant : attentes, annulations, mécontentement.

Question : faut-il imposer un délai minimum entre deux locations et lequel ?



Enjeu 2 - Valorisation des véhicules

Les propriétaires ne savent pas comment valoriser leur véhicule. Un prix trop bas réduit leurs revenus, un prix trop haut décourage les locataires.

Question : peut-on prédire le prix journalier optimal à partir des caractéristiques du véhicule ?

Données et méthodologie

Deux jeux de données complémentaires

`get_around_delay_analysis.xlsx`

21 310 locations - 8 143 véhicules

Variables : type de check-in, état, délai de restitution, écart prévu entre deux locations chaînées

`get_around_pricing_project.csv`

4 843 véhicules - prix journalier

Variables : marque, kilométrage, puissance moteur, carburant, équipements (GPS, climatisation, Connect)

Démarche en quatre étapes

1

Exploration et nettoyage

2

Modélisation et
comparaison

3

Suivi MLflow

4

Déploiement en production

Analyse des retards - chiffres clés

57,5 %

des restitutions sont en retard

sur 16 345 locations analysables

+9 min

délai médian au checkout

moyenne tirée par les valeurs extrêmes

8,6 %

des locations sont chaînées

1 841 cas où une location en suit une autre

12,6 %


des chaînages sont problématiques

le retard précédent dépasse l'écart prévu

Le canal Connect est plus discipliné : 42,9 % de retards contre 61,4 % en Mobile.

Simulation des seuils - arbitrage protection / revenus

Pour chaque valeur de seuil, on mesure le pourcentage de cas problématiques résolus et l'impact sur le chiffre d'affaires (portée : ensemble du parc).



Point d'inflexion

120

minutes

83 %
des problèmes résolus

3 %
d'impact CA seulement

Recommandations produit

Trois scénarios envisageables selon le niveau d'aversion au risque commercial.

Prudent

Risque commercial minimal

Seuil

60 min

Portée

Connect uniquement

Impact CA

< 1 %

Cas résolus

70 % (Connect)

Équilibré

Recommandé

Seuil

120 min

Portée

Ensemble du parc

Impact CA

~ 3 %

Cas résolus

83 %

Protecteur

Protection maximale

Seuil

240 min

Portée

Ensemble du parc

Impact CA

~ 5,5 %


Cas résolus

93 %

Le seuil de 120 minutes sur l'ensemble du parc offre le meilleur ratio efficacité / coût.

Modélisation du prix - pipeline scikit-learn

Le pipeline assure un prétraitement reproductible et déployable.




Suivi des expérimentations - MLflow

Chaque exécution est tracée : hyperparamètres, métriques (MAE, RMSE, R^2) et modèle sérialisé. La comparaison entre les algorithmes devient reproductible et auditable.

Comparaison des modèles

Six algorithmes évalués sur le même jeu de test. Métrique principale : MAE (erreur absolue moyenne en EUR).



Modèle retenu

XGBoost

MAE

9,18 EUR

RMSE

12,82 EUR


R^2

0,846

Une erreur moyenne de moins de 10 EUR sur un prix qui s'étale principalement entre 40 et 250 EUR par jour.

Variables explicatives du prix

Top 7 des variables qui influencent le plus la prédiction du prix journalier (importance XGBoost).



Lecture


La puissance moteur explique à elle seule près de 15 % de la variabilité du prix.

Les équipements de confort (GPS, Connect, climatisation) apportent une plus-value mesurable.

La marque agit comme un proxy de la gamme et du positionnement.

Architecture de déploiement

Deux composants conteneurisés et hébergés sur Hugging Face Spaces.



Composant 1 - API FastAPI

Endpoint /predict (POST)
Documentation HTML personnalisée sur /docs
Monitoring /health

Composant 2 - Dashboard Streamlit

Visualisations Plotly interactives
Simulateur de seuil paramétrable
Filtrage par périmètre (canal de check-in)

Démonstrations en ligne

Trois URLs publiques pour explorer le projet en autonomie.

API de prédiction

Documentation interactive et test du modèle

<https://aichafahugface-getaround-api.hf.space/docs>

Tableau de bord

Analyse interactive avec simulateur de seuil

<https://aichafahugface-getaround-dashboard.hf.space>

Code source

Dépôt Git versionné, documentation complète

<https://github.com/AichaFa/2-Projets-Fullstack>

Illustration - appel à l'API

Une requête HTTP simple suffit pour obtenir une prédiction de prix.

Requête (curl)

```
POST https://aichafahugface-getaround-api.hf.space/predict
Content-Type: application/json

{
  "input": [[
    "Citroën", 140411, 100, "diesel", "black", "convertible",
    true, true, false, false, true, true, true
  ]]
}
```

Réponse (JSON)

```
{
  "prediction": [ 107.97 ]
}
```

Le prix journalier suggéré pour ce véhicule est de 107,97 EUR.

Conclusion et perspectives

Un projet de bout en bout, du jeu de données brut au service consommable par l'équipe Produit.

Livrables

- Recommandations chiffrées sur les seuils de délai entre locations
- Modèle XGBoost (MAE 9,18 EUR, R^2 0,846)
- API REST documentée déployée en production
- Tableau de bord interactif pour l'équipe Produit
- Suivi MLflow reproductible

Pistes d'amélioration

- Tester l'effet réel d'un seuil via un A/B test
- Affiner la segmentation par profil de véhicule
- Ajouter des variables géographiques et saisonnières
- Mettre en place un monitoring du drift du modèle
- Industrialiser le réentraînement périodique

Merci de votre attention